桑乾龙

13569835175 · qlsang@whu.edu.cn · 武汉大学 · codefuturesql.top

教育经历

武汉大学，计算机科学与技术　　工学博士（直博）2022 年 9 月 - 2027 年 6 月

研究方向：

OS 性能功耗优化：使用 CPU 调度和调频等手段优化 OS 性能和功耗
AI For OS：利用强化学习与 Agent 优化操作系统内核参数并开展性能分析
OS For AI：优化端侧模型部署和推理流程，提升推理性能并降低功耗

武汉大学，网络空间安全　　工学学士 2018 年 9 月 - 2022 年 6 月

学术成果

[1] **Qianlong Sang**, Puyi He, Huanghuang Liang, Yili Gong, Chuang Hu, Xiaobo Zhou, Dazhao Cheng "Unleash All Cores: Asymmetry-aware Scalable DNN Inference on Mobile CPUs"（**OSDI '26, CCF-A**）

- 针对非对称多核 CPU 上 DNN 推理负载不均、增加小核反而导致性能下降的问题，设计 SANI 框架；通过核函数亲和感知、动态任务粒度调度与按需核函数切换平衡大小核负载；在五款移动 SoC 上平均降低 17.6%-23.7% 推理时延，部分模型最高降低 29.5%，能耗最高降低 39%。

[2] **Qianlong Sang**, Yuheng Li, Chuang Hu, Yili Gong, Dazhao Cheng "Trident: Identifying, Constraining and Multi-Domain Governing for Resource Management on Mobile Devices." IEEE Transactions on Mobile Computing（**TMC '26, CCF-A**）

- 针对渲染线程识别不准、线程组资源竞争及 CPU/GPU/内存调频割裂的问题，设计 Trident 框架；通过跨层线程追踪、强化学习多域调频与增益调度资源约束协同优化；在五款手机和多类应用上保障 QoE，并较三种先进方案最高降低 16.8% 功耗。

[3] **Qianlong Sang**, Puyi He, Tianyu Tu, Huanghuang Liang, Yaqi Xia, Yili Gong, Chuang Hu, Xiaobo Zhou, Dazhao Cheng "QDiTx: Arbitrary Bit-Width Quantization Framework for Diffusion Transformer" IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems（**TCAD '26, CCF-A**）

- 针对 DiT 迭代去噪导致量化误差累积、非 2 幂位宽引发 GPU 访存不对齐与 bank conflict 的问题，设计 QDiTx 任意比特权重量化框架；通过分辨率感知精度搜索与级联量化控制精度损失，并采用 warp 感知权重布局和 SIMT 并行反量化提升执行效率；在权重加载受限场景实现最高 7 倍加速，FID 相对 FP32 最多增加 6.7%，同位宽较现有方法最高提升 5.39% 生成精度。

[4] **Qianlong Sang**, Jinqi Yan, Rui Xie, Chuang Hu, Kun Suo, Dazhao Chen "QoE-Aware Power Management Via Scheduling and Governing Co-Optimization on Mobile Devices." IEEE Transactions on Mobile Computing（**TMC '24, CCF-A**）

- 针对移动端调度、调频与 QoS 相互割裂导致性能和功耗次优的问题，设计 Orthrus 框架；通过深度强化学习调频、有限状态机调度和专家模糊控制协同分配异构核心资源；在 Google Pixel 3 及多类应用上保障 QoS，并较三种先进方案最高降低 35.7% 平均功耗。

[5] **Qianlong Sang**, Yuheng Li, Junsheng He, Chuang Hu, Yili Gong, Xiaobo Zhou, Dazhao Cheng "Loom: Criticality Inference via Effecient Causal Dependency Graph Mining"（**Submitted**）

- 针对渲染关键线程角色动态变化、跨框架依赖传播隐蔽且传统追踪开销高的问题，设计 Loom 框架；通过轻量级依赖追踪、流式共识图挖掘和切片级资源控制识别关键执行片段；实现 92.26% 平均 F1，平均减少 51.1% 掉帧并最高降低 278mW 功耗。

[6] Yaotian Hu, Chuang Hu, Zheng Gong, **Qianlong Sang**, Zheng Zhang, Xiaobo Zhou, Dazhao Cheng "Nabla: Adaptive Multi-Domain DVFS for Energy-Efficient LLM Inference on Edge SoCs"（**Submitted**）

- 针对端侧 LLM 推理中 prefill/decode 阶段变化与 CPU-GPU-内存竞争相互耦合、传统 DVFS 难以在时延约束下实现最低能耗的问题，提出 Nabla 残差 DVFS 框架；以无干扰执行构建紧凑参考，并结合 Sensitivity Map 在多域 OPP 空间在线修正残差；在 Jetson AGX Orin 上保持推理性能，prefill 能效提升 10%-50%，decode 提升 8%-18%，共置干扰场景提升 3.8%-12.0%。

项目经历

终端设备渲染管线的线程识别技术研究 OPPO · 技术骨干（学生技术 Leader） 2024.09 - 2025.08

- 负责 Android 跨层插桩、线程依赖抽取与流式依赖图挖掘，识别多类渲染管线中的关键线程及动态执行结构
- 在 5 条以上渲染路径和 10 个应用中测试，追踪准确率超过 90%；**方案已在 OPPO A 系列落地，预计 Find 系列搭载**

终端设备下多硬件场景自适应联合调频技术 OPPO · 技术骨干（学生技术 Leader） 2024.03 - 2025.02

- 负责跨应用、跨设备自适应联合调频，使用结构搜索、模型迁移和端侧在线学习实现策略快速适配
- 在 5 类应用和 3 类 SoC 上测试，功耗不增时日均丢帧率降低 10%，性能不劣化时日均功耗降低 5%

动态调频能耗建模与算法技术 华为 · 技术骨干（学生技术 Leader） 2023.03 - 2024.02

- 负责 CPU/内存/GPU 多维性能建模、阶段性负载预测和体验感知调频，定位瓶颈并动态调整硬件频率
- 在视频、会议、浏览器和办公场景测试，保持体验的同时，Top4 整机场景功耗降低 5%

终端设备性能功耗感知的调度调频技术 OPPO · 技术骨干（学生技术 Leader） 2021.12 - 2022.11

- 负责 Android 调度调频协同框架设计，使用深度强化学习、状态机和模糊控制动态分配异构核心与频率
- 在多类移动应用中测试，性能不劣化时日均整机功耗降低 5%

实习经历

腾讯 青云计划实习生 2026.06 - 2026.11

- 负责 Agent for OS 相关能力的维护与问题定位，保障系统侧 Agent 功能的稳定迭代
- 优化长上下文信息筛选、上下文复用与任务记忆机制，提升 Agent 执行效率并降低上下文与调用成本

华为 项目合作（实习） 2025.06 - 2026.04

- 负责帧负载感知建模、时延感知 CPU 调度与 CPU/GPU 协同调频策略，并在浏览器、视频、会议和办公场景验证，实现约 5% 的加权整机功耗收益

OPPO 科研实习生 2022.02 - 2022.05

- 开展移动端系统性能和功耗分析，聚焦内核调度、调频模块的表现，并提出相关功耗优化方案

一生一芯第三期 助教 2021.07 - 2021.10

- 基于二期 RISC-V CPU 设计的完整实现，为学生讲解五级流水线架构等核心概念，并为学生答疑解惑

荣誉奖项

武汉大学国家奖学金

武汉大学国家励志奖学金

武汉大学乙等奖学金

滴滴 e 鸣博士论坛二等奖

武汉大学优秀学生

第四届龙芯杯（计算机学院 Ⅱ 类 A 类学科竞赛）全国三等奖

技能特长

编程与系统： 熟练使用 Python 与 C/C++，具备 Linux/Android 系统开发、跨层追踪及性能功耗分析经验
端侧 AI 推理： 熟悉 PyTorch、端侧模型部署、异构 CPU 并行、模型量化、推理框架及 CPU/GPU/内存协同优化
系统性能优化： 熟悉 CPU 调度、DVFS、关键线程识别、QoS/QoE 建模与移动端性能稳定性分析
Agent 工程： 具备 Agent harness、上下文管理、记忆机制和系统工具协同的研发维护经验
英语水平： CET-6 560

自我评价

学习能力较强，面对陌生领域能够快速梳理关键问题、补充所需知识并推进落地。遇到问题喜欢追根究底，愿意花时间定位原因并找到可验证的解决方案。对操作系统内核机制与性能优化始终保持热情，也乐于挑战有难度的任务，并从持续探索和解决问题的过程中获得成就感。